KMP 算法设计与分析

引言

在字符串初级算法里, 最基础的算法是字符 串匹配算法, 而其中最经典的模型问题 就是 判断一个串是否是另一个串的子串。关于字 符串算法有一个通用的解题方法,即抓住问 题相关的字符串的某种性质,通过这个字符 串性质来高效解决问题。很多人可能会认为 字符串题目很有难度,不知道从何入手,变 化多端,难以琢磨。其实不然,字符串算法 的不同模型可能有很多,

引言

但, 只要能把特定模型的基本方法、原理弄 透,不管题目如何变化多端,都万变不离其 中,可以用特定的方法去解决,无非有时需 要配上一些额外技巧、科技罢了。所以,对 于初学算法的人,切勿一开始就对字符串形 成望而生怯的毛病,而应该养成正确思考字 符串问题的好习惯——用算法对应的字符串 性质来解题.

KMP算法

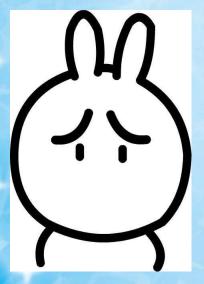
- · 在字符串算法里,最简单、基础的就是 KMP算法。下面就来看一下
- KMP算法能处理什么样的问题?
- KMP算法用到了什么字符串性质?
- KMP算法实现原理是什么?
- · KMP算法的时间复杂度?
- KMP算法的拓展应用?

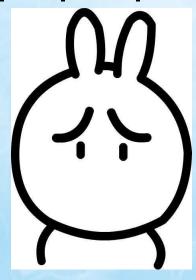
问题

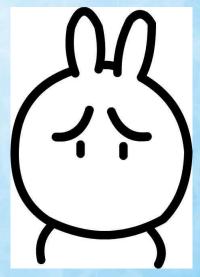
下面我们先来看这么一个问题:

给两个字符串S1和S2,问S2是否是S1的子串?

数据范围: 0<|S2|<=|S1|<=100000







输入和输出

Input

第一行输入一个字符串S1, 第二行输入一个字符串S2, 保证0<|S2|<=|S1|<=100000

Output 如果S2是S1的子串,输出"YES". 否则,输出"NO".

样例

- Sample Input
- AAABAAABAAABAAAD
- AAABAAAD

- ABAAB
- ABB

- Sample Output
- YES
- · NO

一个字符串的子串指的是字符串某一段连续的部分 (比如第一个例子),可以是其本身。 而不连续的部分,一般称作为子序列!(比如第二个例子,ABB是ABAAB的子序列而不是子串)

KMP算法用到了什么字符串性质

- 下面介绍下KMP用到的字符串性质
- 是否还记得刚才说的?
- 每个字符串算法都对应它的字符串性质!
- 我们定义这么一个字符串性质,叫前缀后缀最大值!
- 光从定义来看,似乎是和字符串的前缀、 后缀有关系,同时告诉你,最大值指的是 长度最大,什么长度最大?下面具体来看 下这个性质。

- 一个长度为N的字符串S,它有N+1个前缀(包括空前级),它有N+1个后缀(包括空后级)
- 比如ABC,有4个前缀,空,A,AB,ABC
 有4个后缀,空,C,BC,ABC
- 比如AAA,有4个前缀,空,A,AA,AAA有4个后缀,空,A,AA,AAA

举一个容易看出性质的例子, S=ABABABA

前缀	后缀	相等
空	空	yes
A	A	yes
AB	ВА	no
ABA	ABA	yes
ABAB	BABA	no
ABABA	ABABA	yes
ABABAB	BABABA	no
ABABABA	ABABABA	yes

容易发现,S有5个 前缀与后缀相等,如果 我们不算自身,即前缀 ABABABA不算. 后缀ABABABA不算, 那么, 在所有相等的 <前缀,后缀>里, 长度最大的就是 ABABA, 则前缀后缀 最大值就是5!

一个字符串S,长度为N.

找出它的N+1个前缀(包括空前缀)

找出它的N+1个后缀(包括空后缀)

按照长度划分,得到N+1对序偶<前缀,后缀>

删除前缀、后缀等于S的<前缀,后缀>,得到 N对<前缀,后缀>。

在这N对中,找到一对满足:

1. 前缀 = 后缀 2. 前缀后缀的长度最大

该长度就是S的前缀后缀最大值!

下面我们拿暴力匹配算法中的模板串

S=AAABAAAD 来具体阐述!

我们定义一个数组: int next[N];

next[i]表示 S[0...i-1] 这个前缀的前缀后缀最大值!

接下来,我们分析字符串S的每一个前缀的next值,即每一个前缀的前缀后缀最大值。然后,我们再介绍如果使用这个next数组!

重要的话要多讲几遍!

next[i]表示 S[0...i-1] 这个前缀的前缀后缀最大值!

next[i]表示 S[0...i-1] 这个前缀的前缀后缀最大值!

请务必牢记这个定义! KMP核心部分就是这个next数组。对next数组的理解透彻与否决定你能否快速、准确地解决KMP相关的题目! 注意,是S[0...i-1] 不是S[0...i]!

同时务必正确理解前缀后缀最大值的含义!

```
i 0 1 2 3 4 5 6 7 8

S A A B A A D

nex -1
t
```

S=AAABAAAD,第0个前缀:空前缀

空前缀的next值我们直接定义为 -1

即next[0]=-1. 记得之前的"删除前缀、后缀等于S的<前缀,后缀>"的操作吗?

删除后找不到<前缀,后缀>,next值为-1

```
i 0 1 2 3 4 5 6 7 8

S A A B A A D

nex -1 0
t
```

S=AAABAAAD,第1个前缀: A

next[1]=0. 表示S[0...0]的前缀后缀最大值是0

一个前缀:空

一个后缀:空

显然, next[1]=|空|=0

```
i 0 1 2 3 4 5 6 7 8

S A A B A A D

nex -1 0 1
t
```

S=AAABAAAD, 第2个前缀: AA

next[2]=1. 表示S[0...1]的前缀后缀最大值是1

两个前缀:空,A

两个后缀:空,A

显然, next[2]=|A|=1

```
i 0 1 2 3 4 5 6 7 8

S A A A B A A D

nex -1 0 1 2
t
```

S=AAABAAAD, 第3个前缀: AAA

next[3]=2. 表示S[0...2]的前缀后缀最大值是2

三个前缀:空,A,AA

三个后缀:空,A,AA

显然, next[3]=|AA|=2

```
i 0 1 2 3 4 5 6 7 8

S A A A B A A A D

nex -1 0 1 2 0
t
```

S=AAABAAAD, 第4个前缀: AAAB

next[4]=0. 表示S[0...3]的前缀后缀最大值是0

四个前缀:空,A,AA,AAA

四个后缀:空,B,AB,AAB

显然, next[4]=|空|=0

```
i 0 1 2 3 4 5 6 7 8

S A A A B A A D

nex -1 0 1 2 0 1
t
```

S=AAABAAAD, 第5个前缀: AAABA

next[5]=1. 表示S[0...4]的前缀后缀最大值是1

五个前缀:空,A,AA,AAA,AAAB

五个后缀:空,A,BA,ABA,AABA

显然, next[5]=|A|=1

i	0	1	2	3	4	5	6	7	8
S								D	
nex t	-1	0	1	2	0	1	2		

S=AAABAAAD,第6个前缀: AAABAA

next[6]=2. 表示S[0...5]的前缀后缀最大值是2

空, A, AA, AAA, AAAB, AAABA

空, A, AA, BAA, ABAA, AABAA

显然, next[6]=|AA|=2

i	0	1	2	3	4	5	6	7	8
S	Α	Α	Α	В	Α	Α	Α	D	
nex t	-1	0	1	2	0	1	2	3	

i	0	1	2	3	4	5	6	7	8
S									
nex t	-1	0	1	2	0	1	2	3	0

S=AAABAAAD, 第8个前缀: AAABAAAD

next[8]=0. 表示S[0...7]的前缀后缀最大值是0空,A,AA, AAA, AAAB, AAABA, AAABAA, AAABAAA 空,D,AD,AAD, AAAD, BAAAD, ABAAAD, AABAAAD

显然, next[8]=|空|=0

得到next数组

i	0	1	2	3	4	5	6	7	8
S									
nex t	-1	0	1	2	0	1	2	3	0

我们得到S串的next数组

再次回忆, next[i]表示S[0...i-1]这个前缀的前缀后缀最大值。

那么,有什么用呢?! 它与子串匹配有什么关系呢?

回顾与分析

给两个字符串S1和S2,问S2是否是S1的子串?

S1=AAABAAABAAABAAAD

S2=AAABAAAD

在这个问题中, 我们得到文本串S1和模板串S2.

现在想判断S2(单词)是否是S1(文章)的子串。

我们先对模板串S2,构建next数组,得到S2每一个前缀的前缀后缀的最大值。

接下来,开始KMP匹配过程!

KMPITE HT

```
      S1
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      A
      D

      i
      0
      1
      2
      3
      4
      5
      6
      7
      8
      9
      1
      11
      1
      1
      1
      1
      5

      S2
      A
      A
      A
      B
      A
      A
      A
      A
      D
      III
      III
```

设两个变量 int t1, t2; t1表示当前扫到S1串的位置, t2表示当前扫到S2串的位置。起初, t1=t2=0; S1[t1]=S2[t2]=A, t1++, t2++; //t1=1, t2=1 S1[t1]=S2[t2]=A, t1++, t2++; //t1=2, t2=2 S1[t1]=S2[t2]=A, t1++, t2++; //t1=3, t2=3 S1[t1]=S2[t2]=B, KMPITTAZ

```
S1 A A A B A A B A A B A A A B A A B A A A D

i  0 1 2 3 4 5 6 7 8 9 1 1 1 1 1 1 1 1

52 A A A B A A A D

j  0 1 2 3 4 5 6 7 8

next -1 0 1 2 0 1 2 3 4
```

S1[t1]=S2[t2]=A, t1++, t2++; //t1=t2=7

此时发现,S1[t1]!= S2[t2]

```
      S1
      A
      A
      A
      B
      A
      A
      A
      B
      A
      A
      B
      A
      A
      A
      B
      A
      A
      A
      D

      S2
      A
      A
      A
      B
      A
      A
      A
      A
      D
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I</th
```

此时, t1=7, t2=7, S1[t1]=B, S2[t2]=D 出现不相等! 在之前的暴力匹配算法中, 这说明了什么? 说明了从 t1=0 这个起始位置开始, 往后长度为|S2|的子串不与S2匹配, 那么, 在暴力算法中, 接下来应该枚举下一个起始位置 t1=1, 再往下判断, 是吧? 但是!在KMP中有所不同!

```
      S1
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      A
      A
      B
      A
      A
      A
      D

      S2
      A
      A
      A
      B
      A
      A
      A
      A
      D
      Image: Control of the con
```

在KMP中, S1[7]!=S2[7], 此时出现了失配! 怎么办呢? 我们查询7号位置的next值, 即next[7]=3. 然后, 我们直接令t2=next[t2]=next[7] (next[7]=3);相 坐工地C2大孩子/按 下面 我们生业美下这个独态的

当于把S2右移了4格,下面,我们先来看下这个神奇的变化!再分析下这么做的理由和优势。

S1	A	A	A	В	A	A	A	В	Α	Α	Α	В	Α	Α	Α	D
i	0	1	2	3	4	5	6	7	8	9			1 2	1	1 4	1 5
S2 `	A	A	A	В	A	A	A	D								
j	0	1	2	3	4	5	6	7	8							
next	-1	0	1	2	0	1	2	3	4							
S2					A	A	A	В	A	A	A	D				
j					0	1	2	3	4	5	6	7	8			
next					-1	0	1	2	0	1	2	3	4			

S1未动, S2整体往右移动了 |S2| - next[7] 个格子

S1	A	Α	Α	В	A	A	A	В	A	A	A	В	A	Α	Α	D
i	0	1	2	3	4	5	6	7	8	9					1 4	
S2					A	A	A	В	Α	Α	A	D				
j					0	1	2	3	4	5	6	7	8			
next					-1	0	1	2	0	1	2	3	4			

此时,我们只需从 t1=7, t2=3 这个匹配对开始往下继续匹配即可。而S1[4...6]与S[0...2]相当于已经匹配成功了,不需要再匹配。

想想看,为什么可以这么做?

```
      S1
      A
      A
      A
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      B
      A
      A
      A
      D

      S2
      A
      A
      A
      B
      A
      A
      A
      A
      D
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I
      I</th
```

我们在匹配时, 是不是已经得到S1[0...6]=S2[0...6]了?

然后,通过next数组,next[7]=3,是不是我们就知道 S2[0...2]=S2[4...6]这个性质?于是我们就可以推得 :S2[0...2]=S1[4...6],又由于next[7]表示S2[0..6]这个前缀的前缀 后缀最大值!所以,这样挪动是正确的!

正确可行的匹配一定会延续到S1的位置7,这样挪动和将i退回到1是等价的,退回到1,新的匹配也是S1的后缀和S2的前缀匹配。

 S1
 A
 A
 A
 B
 A
 A
 B
 A
 A
 B
 A
 A
 B
 A
 A
 A
 A
 B
 A
 A
 A
 D

 S2
 A
 A
 A
 B
 A
 A
 A
 A
 D

 j
 0
 1
 2
 3
 4
 5
 6
 7
 8

 next
 -1
 0
 1
 2
 0
 1
 2
 3
 4

换句话说,我们在S1[7]与S2[7]处出现了失配,此时 t1不需要返回,只需改变t2。在7处失配,则只需查询 S2[0...6]处的前缀后缀最大值,表示某一段前缀等于后 缀,而又是长度最大的!那么移动后,失配点的前段 一定还是匹配的,而只需在从失配点往下匹配即可, 若失配点还是失配,再继续改变t2

S 1	A	A	A	В	A	A	A	В	A	A	A	В	A	A	A	D
i	0	1	2	3	4	5	6	7	8	9					1 4	
S2					A	A	A	В	Α	Α	Α	D				
j					0	1	2	3	4	5	6	7	8			
next					-1	0	1	2	0	1	2	3	4			

失配点是 i=7,j=3,失配点的前一段S1[4...6]=S2[0..2] 仍然匹配,现在只需从失配点,t1=7,t2=3,继续往下匹配即可...

当next[t2]==-1,表示S2的首个字符和S1的第i个字符都不匹配,那么i就加1

S1	Α	A	A	В	A	A	A	В	A	A	A	В	A	A	Α	D
i	0	1	2	3	4	5	6	7	8	9					1 4	
S2					A	A	A	В	A	A	A	D				
j					0	1	2	3	4	5	6	7	8			
next					-1	0	1	2	0	1	2	3	4			

好! 我们继续往下匹配,发现t1=11,t2=7的时候, 又出现了失配! 与刚才同样的步骤,令 t2=next[t2]=next[7].

S1	Α	Α	Α	В	A	A	A	В	A	A	A	В	A	Α	Α	D
i	0	1	2	3	4	5	6	7	8	9	1 0	1 1	1 2	1	1 4	1 5
S2 `					A	A	A	В	A	A	A	D				
j					0	1	2	3	4	5	6	7	8			
next					-1	0	1	2	0	1	2	3	4			
S2									A	A	A	В	A	A	A	D
j									0	1	2	3	4	5	6	7
next									-1	0	1	2	0	1	2	3

S1未动, S2整体往右移动了 |S2| - next[7] 个格子

S1	A	A	Α	В	A	A	Α	В	A	A	A	В	A	A	A	D
i	0	1	2	3	4	5	6	7	8	9			1 2			
S2									A	A	A	В	A	Α	Α	D
j									0	1	2	3	4	5	6	7
next									-1	0	1	2	0	1	2	3

从 i=11, j=3这个匹配对, 继续往下匹配...

前一段S1[8...10]与S2[0...2]已经匹配成功!

S1	A	A	A	В	A	A	Α	В	A	A	A	В	A	A	A	D
i	0	1	2	3	4	5	6	7	8	9			1 2			
S2									A	A	A	В	A	A	A	D
j									0	1	2	3	4	5	6	7
next									-1	0	1	2	0	1	2	3

继续往下匹配,都能匹配成功! 发现S2[0...7]与S1[8...15]完全匹配成功! S2是S1的子串。

代码: 构建next数组

```
void get_next(int *next,char *s2,int lens){
 //用于构建s2的next数组,kmp的前奏
  int t1=0,t2;
  next[0]=t2=-1;
  while(t1<lens){
    if(t2==-1||s2[t1]==s2[t2])
       next[t1+1]=t2+1;
       t1++;
       t2++;
     else t2=next[t2];
```

代码: KMP匹配

```
bool kmp(int *next,char *s1,int lens1,char *s2,int
lens2){ //用于判断S2是否是S1的子串
  int t1=0,t2=0;
  while(t1<lens1&&t2<lens2){
    if(t2==-1||s1[t1]==s2[t2])
       t1++;
       t2++;
    else t2=next[t2];
  if(t2==lens2) return true;//S2是S1子串
  else return false;//S2不是S1子串
```

代码:KMP匹配2

```
int kmp(int *next,char *s1,int lens1,char *s2,int lens2){
  int t1=0,t2=0;
  int times=0;
  while(t1<lens1){
     if(t2==-1||s1[t1]==s2[t2]){
       t1++;
       t2++;
     else t2=next[t2];
     if(t2 = lens2){
       times+=1;
       t2=next[t2];
  }//求S2在S1中出现了多少次
  return times;
```

KMP的用途

- 1. 判断一个串是否是另一个串的子串。
- 2. 判断一个串在另一个串出现了多少次。
- 3. 求一个字符串的最小循环节.
- 4. 进行各式各样的字符串匹配,模糊匹配等 (kmp匹配只是最经典的匹配一种,很多时候 是需要在失配函数上做文章,完成另类的匹配)
 - 5..... 等等